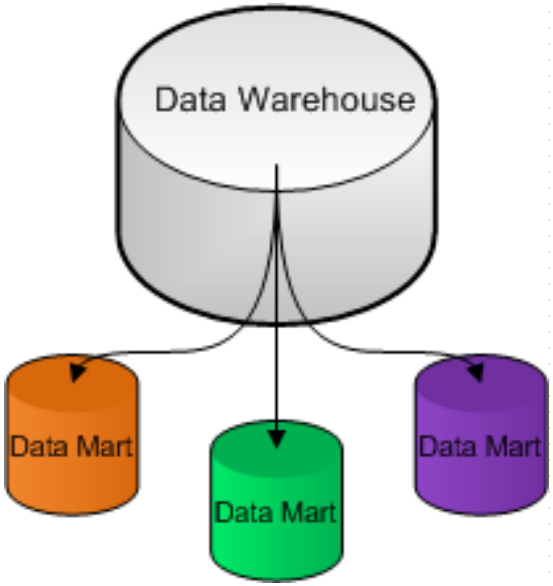
Informatique Décisionnelle

2 - Les entrepôts de données (Data Warehouse)

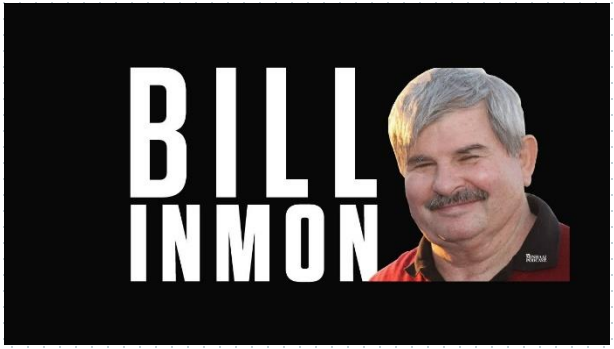


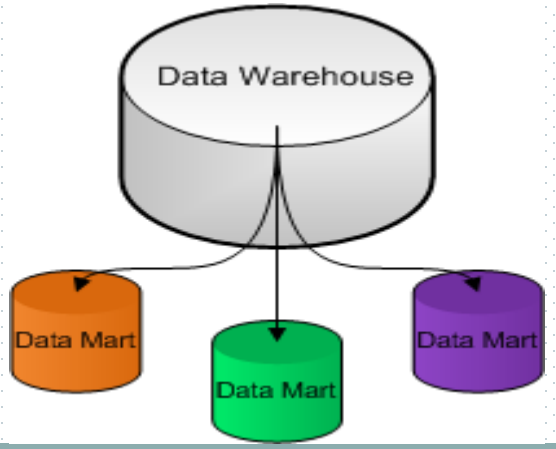
CYCLE D'INGÉNIEUR : ILTI
ANNÉE UNIVERSITAIRE 2024/2025
ANIMÉ PAR : M. RIYAMI bouchaib.riyami@iga.ac.ma

Entrepôt de données : Data Warehouse

- Définitions :
- Un entrepôt de données est une base de données dans laquelle sont recopiées des données opérationnelles, mais à laquelle aucune application opérationnelle (système opérant) n'accède.
- Base de données dans laquelle sont déposées après nettoyage et homogénéisation les informations en provenance des différents systèmes de production de l'entreprise OLTP
- Le Datawarehouse (Entrepôt de Données) est le lieu de stockage intermédiaire des différentes données en vue de la constitution du système d'information décisionnel.
- Le créateur du concept de DatawareHouse, *Bill Inmon*, le définit comme suit :

« *Un datawarehouse est une collection de données thématiques, intégrées, non volatiles et historisées pour la prise de décisions.* »





Entrepôt de données : Data Warehouse

Caractéristiques des données :

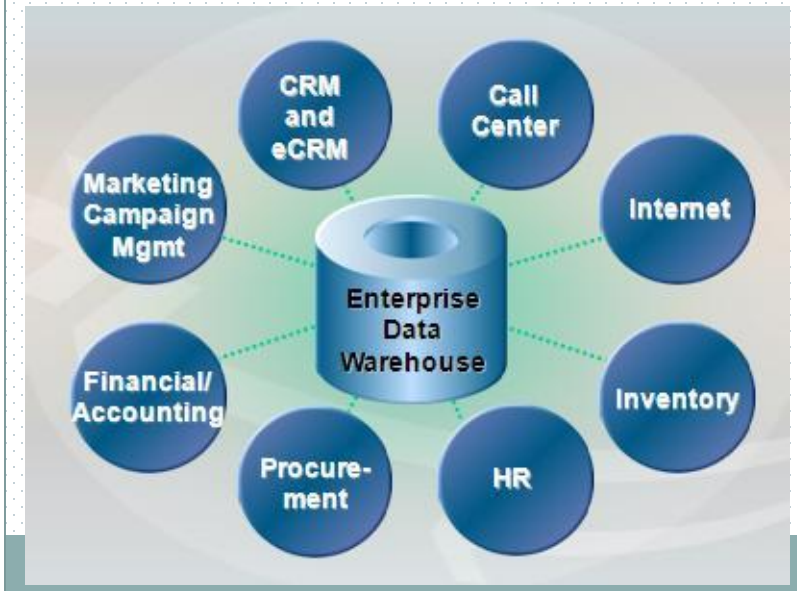
- Orientées sujet :
  - Les données sont organisées pour répondre à des besoins « métiers » : elles sont classées par thème.
  - Les données propres à un thème, les ventes par exemple, seront rapatriées des différentes bases OLTP (Online transaction processing) de production et regroupées.
  - Données pour l'analyse et la modélisation en vue de l'aide à la décision, et non pas pour les opérations et transactions journalières.
  - Vue synthétique des données selon les sujets intéressant les décideurs.
- Intégrées :
  - Les données proviennent de sources hétérogènes utilisant chacune un type de format. Elles sont intégrées avant d'être proposées à utilisation. Un « nettoyage » préalable des données est nécessaire dans un souci de rationalisation et de normalisation.
  - Les données doivent être mises en forme et unifiées afin d'avoir un état cohérent.
  - Phase la plus complexe (60 à 90 % de la charge totale d'un projet DW).
- Non volatiles
  - Les données une fois intégrée dans l'entrepôt ne sont pas appelées à être supprimées. (Read-Only).
  - Une même requête effectuée à intervalle de temps, en précisant la date référence de l'information donnera le même résultat.
  - Stockage indépendant des BDD opérationnelles;
  - Pas de mise à jour des données dans le DW.
- Historisées
  - Les données mémorisées sont datées. Il est ainsi possible de visualiser leur évolution dans le temps.
  - Le degré de détail de l'archivage est bien entendu relatif à la nature des données. Toutes les données ne méritent pas d'être archivées.
  - Un référentiel temps doit être associe aux données.
  - Matière première pour l'analyse.

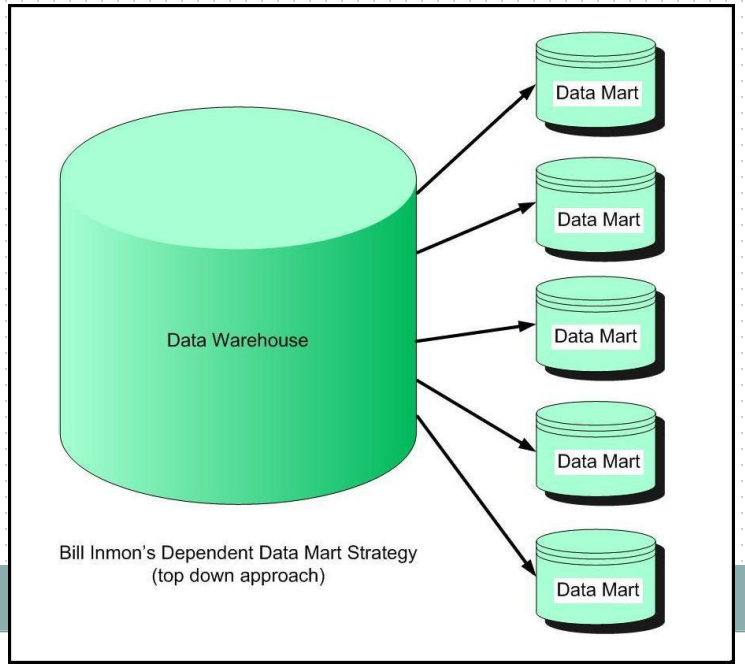
Entrepôt de données : Data Warehouse

- Datamart :

Les « entrepôts de données» partiels, limités à un domaine particulier sont qualifiés de « **datamart** ». Par exemple, dans le domaine marketing, se trouvent des datamart contenant une base clients et prospects.

Les *datamarts*, peuvent être considérés comme des sous-référentiels de données ou vues par métier de l'entreprise (service client, etc.). Cet éclatement permet aux outils d'analyse d'accéder plus facilement au *datawarehouse*.





Entrepôt de données : Data Warehouse

Datamart : Caractéristiques

- Orienté vers un sujet unique
  Ex: comportement de la clientèle
- Données fortement agrégées
  Le DW joue le rôle de source et d'historique pour le Datamart
- Organisation multidimensionnelle (cubique)
  Dont l'une des dimensions indique souvent le temps
- Lien dynamique avec le DW
  Association entre valeur agrégée et valeur détaillée
- Interfaces simples et conviviales.

Entrepôt de données : DataWwarehouse

- Données multidimensionnelles :

- Notion de dimension : C'est une catégorie linguistique selon laquelle les données sont organisées:
  - Nom d'un attribut
  - Valeur d'un attribut

Représentation

DuréeMoy	Départ.	Mois	Année
5	Info	Janv	1998
5	Phys	Janv	1998
18	Philo	Janv	1998
7	Droit	Janv	1998
12	Info	Févr	1998
8	Phys	Févr	1998
9	Philo	Févr	1998
15	Droit	Févr	1998
18	Info	Mars	1998
12	Phys	Mars	1998
22	Philo	Mars	1998
25	Droit	Mars	1998

Tableau simple

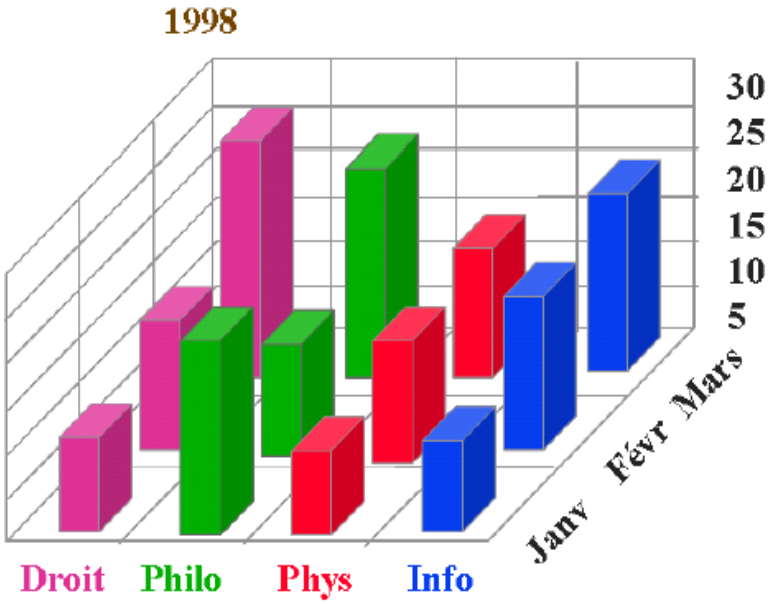
1998	Janv	Févr	Mars
Info	5	12	18
Phys	5	8	12
Philo	18	9	22
Droit	7	15	25

Tableau croisé

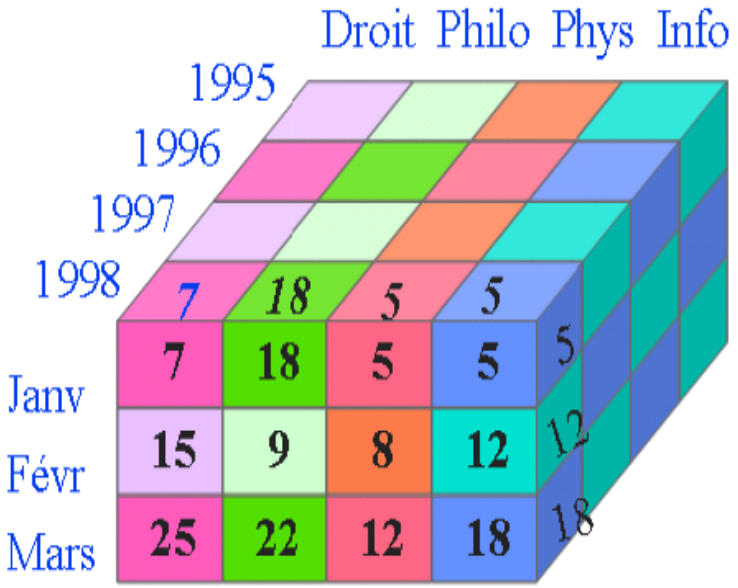
Entrepôt de données : Data Warehouse

- Données multidimensionnelles :

Représentation :



Graphique 3D



Hyper cube:

Entrepôt de données : Data Warehouse

- OLAP et Analyse multidimensionnelles :

OLAP :

- « Il s'agit d'une catégorie de logiciels axés sur l'exploration et l'analyse rapide des données selon une approche multidimensionnelle à plusieurs niveaux d'agrégation ».
- OLAP vise à assister l'usager dans son analyse en lui facilitant l'exploration de ses données et en lui donnant la possibilité de le faire rapidement.
    - L'usager n'a pas à maîtriser des langages d'interrogation et des interfaces complexes.
    - L'usager interroge directement les données, en interagissant avec celles-ci.

Entrepôt de données : Data Warehouse

- OLAP et Analyse multidimensionnelles :

Modèle conceptuel :

Approche multidimensionnelle

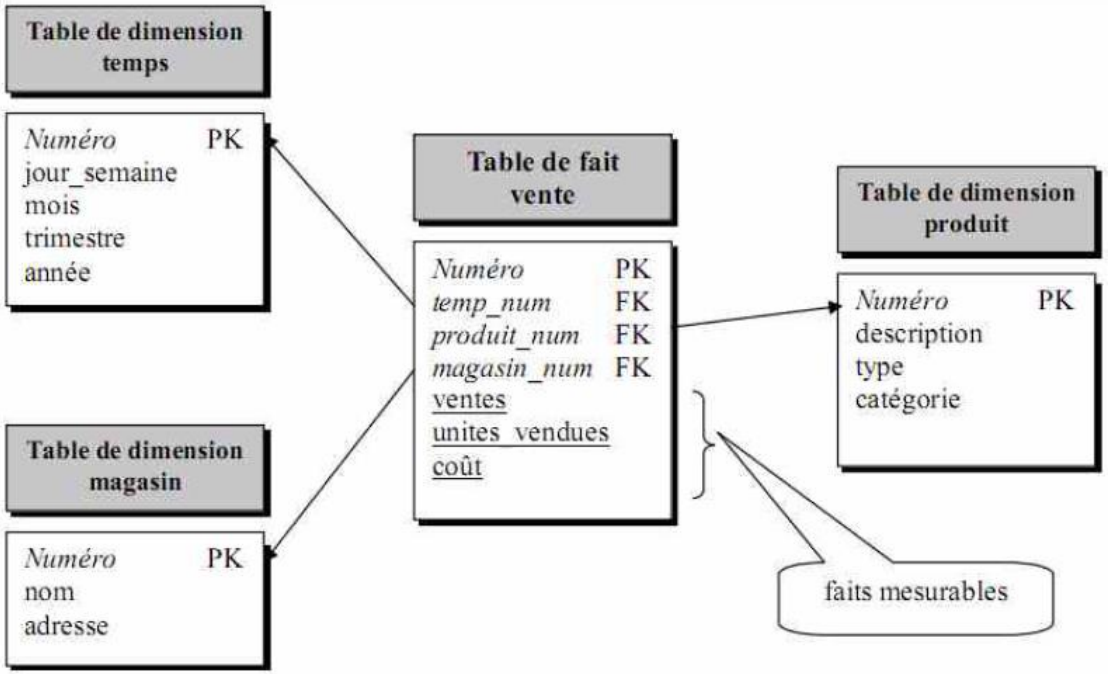
- Souvent représentés par une structure à plusieurs dimensions
- Une dimension est un attribut ou un ensemble d'attributs:
    - Temps
    - Géographie
    - Produits
    - Clients
- Les cellules contiennent des données agrégées appelées Faits ou Indicateurs:
    - Nombre d'unités vendues
    - Chiffre d'Affaire
    - Coût
- Représentations:
    - Relations,
    - Cube de données,
    - hyper cube de données

Entrepôt de données : Data Warehouse

Modèle dimensionnel :

- La modélisation consiste à transformer les résultats de l'analyse des besoins en un modèle dimensionnel. Ce type de modélisation diffère fortement de la modélisation entité-association.
- La modélisation entité-association vise à éliminer les redondances et est particulièrement bien adapté aux transactions; Le modèle dimensionnel est lui conçu pour être interrogé de manière particulièrement efficace.

Le schéma en étoile



Entrepôt de données : Data Warehouse



- **Table des faits :**

Une table des faits est une table qui contient les données à analyser. Ce type de table comporte un grand nombre de clés étrangères afin de la lier avec des tables de dimension.

- **Les faits :**

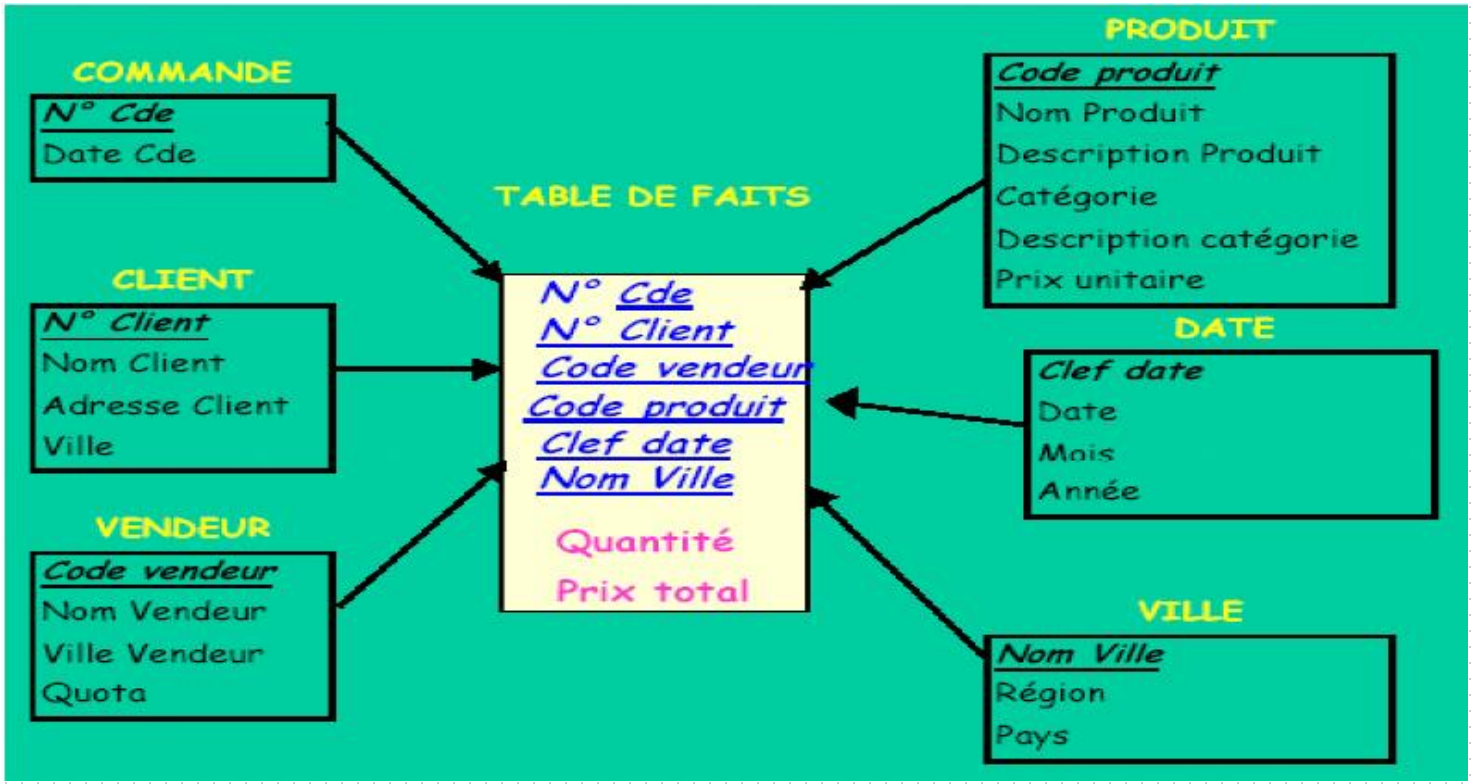
Les champs qui ne sont pas clés étrangères sont les faits. Ils doivent être valorisés de façon continue et être additifs.

- **Tables de dimensions :**

Les tables qui entourent la table des faits sont appelées « tables de dimension ». Ces tables sont composées d'attributs qui sont la plupart du temps de type caractère et discret. Ces attributs servent à stocker la description des dimensions et sont utilisés comme source de contraintes et d'en-tête de ligne dans le jeu de réponses de l'utilisateur.

Entrepôt de données : Data Warehouse

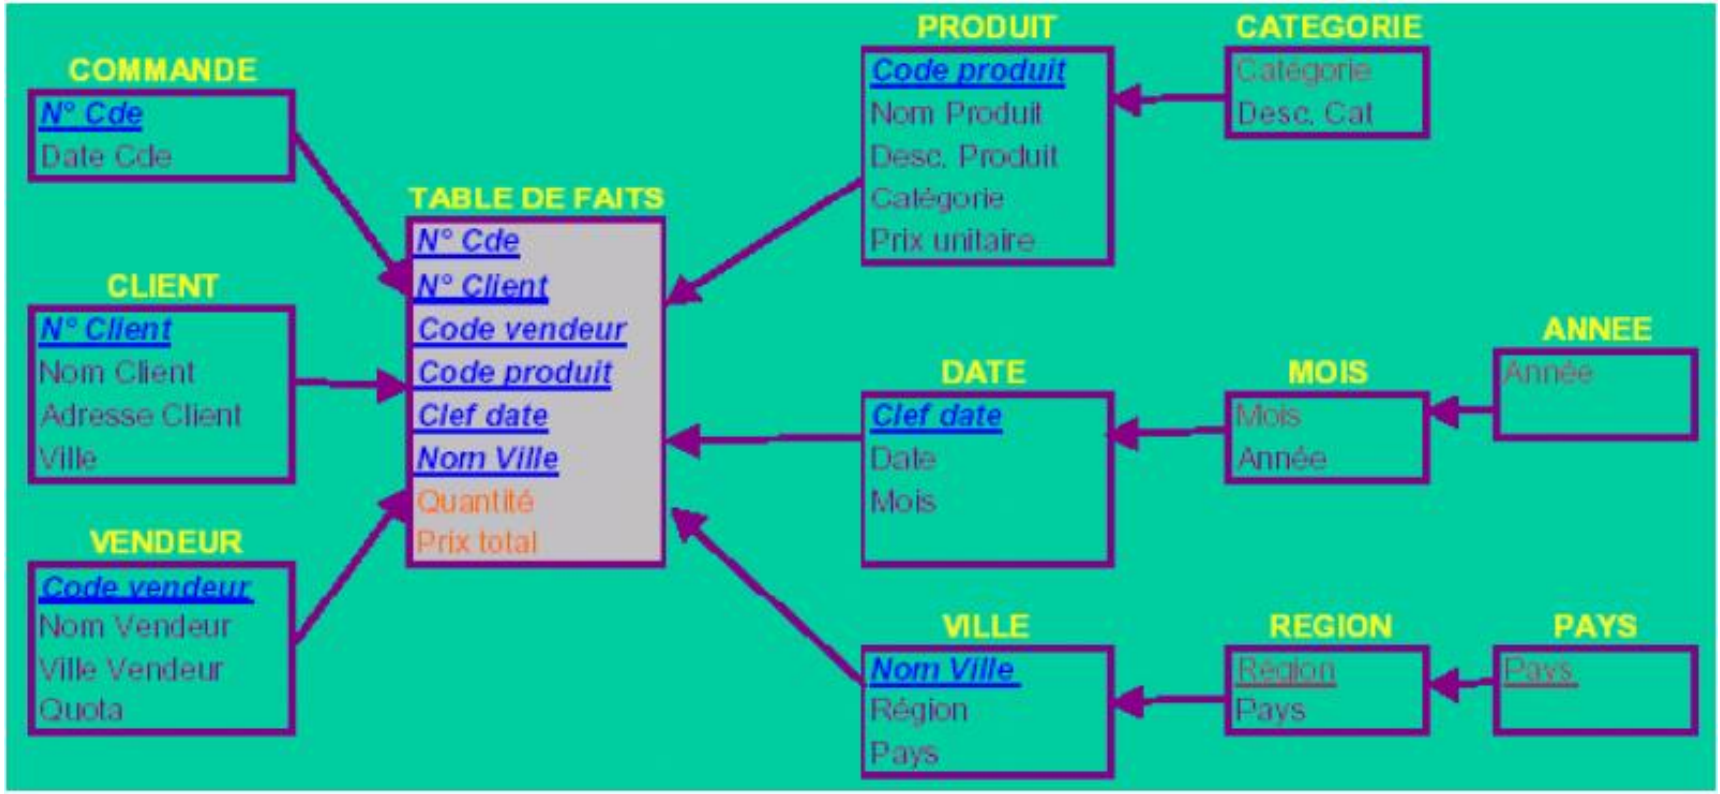
Modèle dimensionnel : Schéma en étoile



- Une (ou plusieurs) table(s) de faits : identifiants des tables de dimension ; une ou plusieurs mesures.
- Plusieurs tables de dimension : descripteurs des dimensions.

Entrepôt de données : Data Warehouse

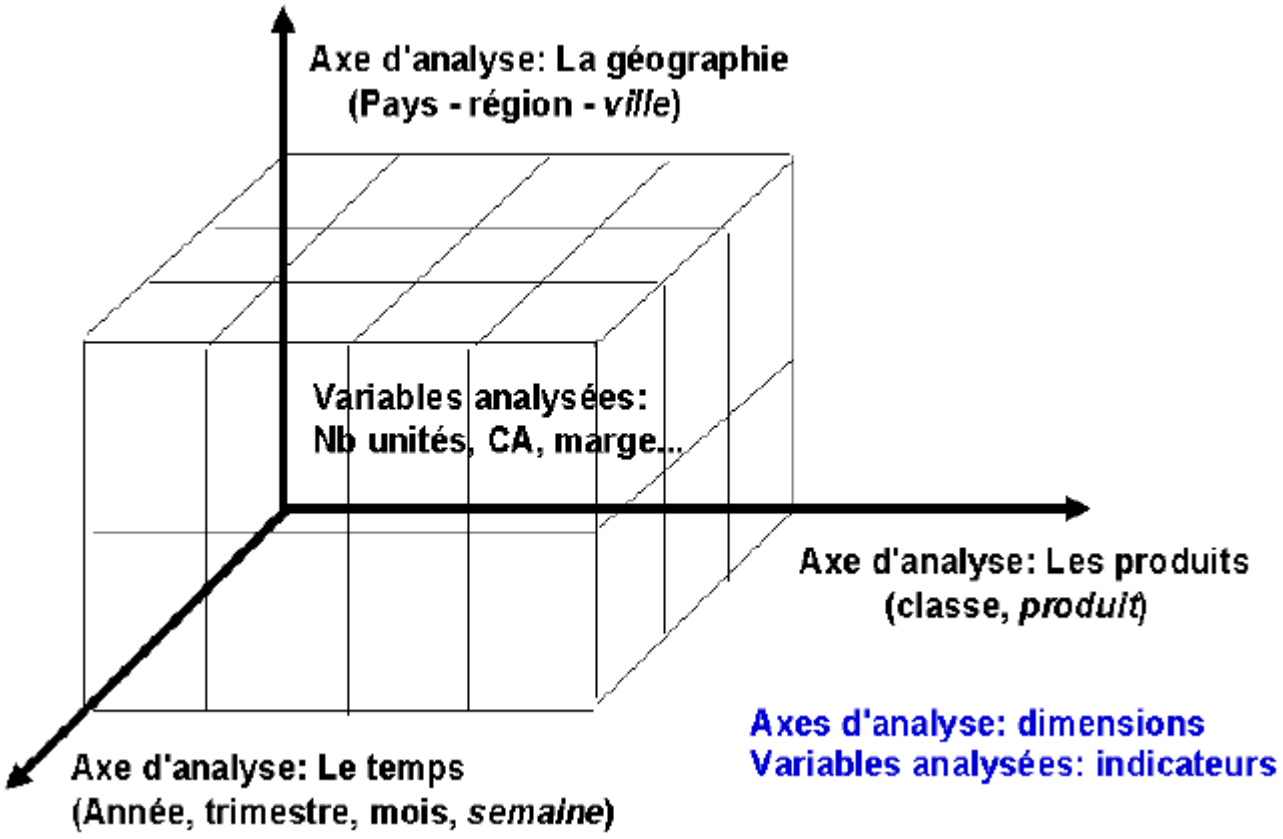
Modèle dimensionnel : Schéma en flocons de neige



- Raffinement du schéma étoile avec des tables normalisées par dimensions.

Entrepôt de données : Data Warehouse

- Vue Multidimensionnelles :



Entrepôt de données : Data Warehouse

- Agrégation des données :

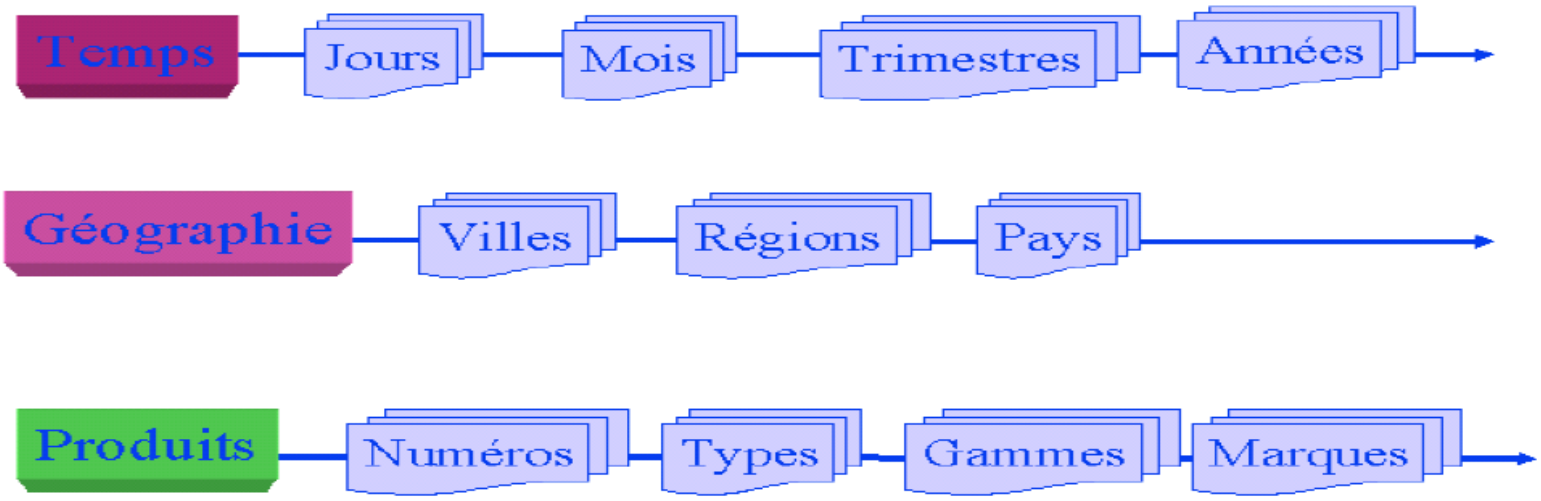
  - Plusieurs niveaux d'agrégation

    - Les données peuvent être groupées à différents niveaux de granularité
    - Les regroupements sont pré-calculés,

      Par exemple, le total des ventes pour le mois dernier calculé à partir de la somme de toutes les ventes du mois.

  - Granularité : niveau de détail des données emmagasinées dans un Datawarehouse.

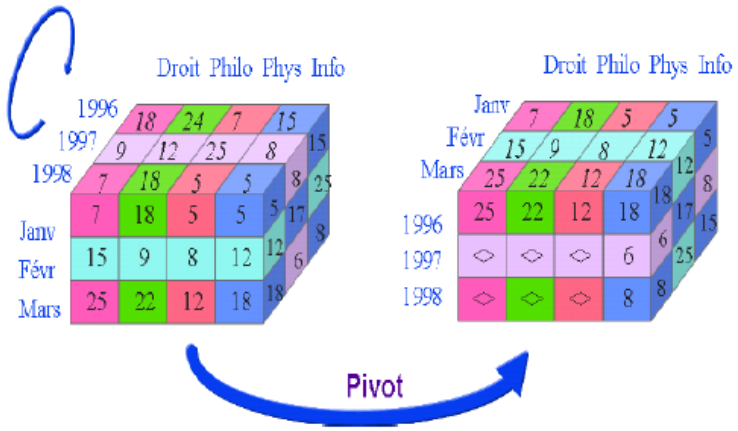
Granularité des dimensions



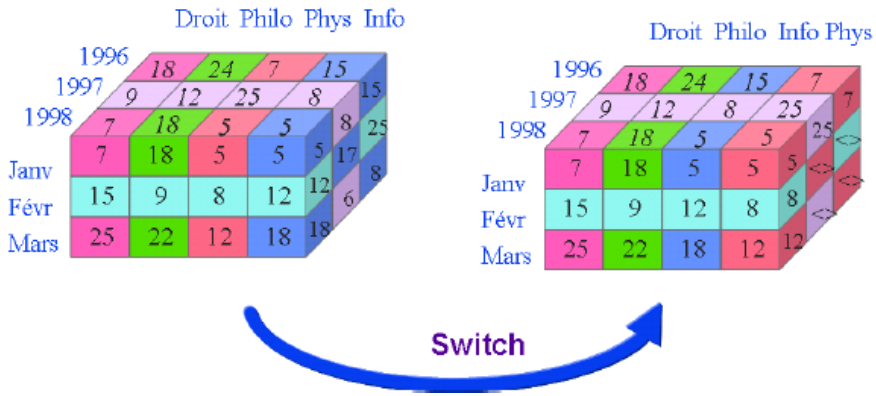
Entrepôt de données : Data Warehouse

Opération sur les OLAP : Opérations sur les structures des cubes :

- Pivot (Rotation)



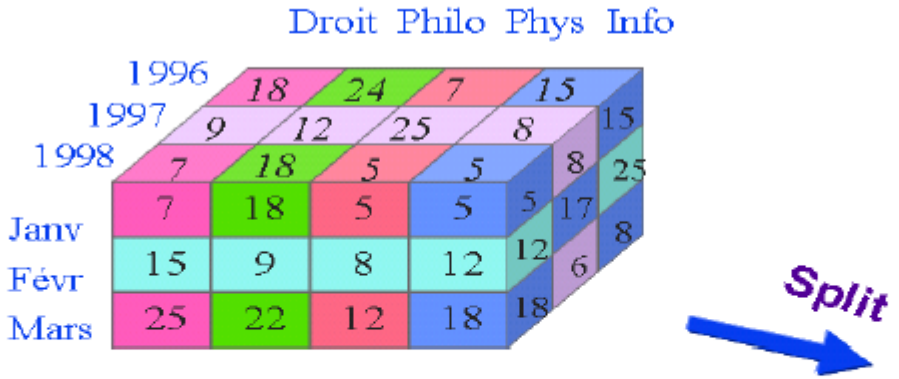
- Switch (Permutation)



Entrepôt de données : Data Warehouse

Opération sur les OLAP : Opérations sur les structures des cubes :

- Split (Décomposition



Droit	1998	1997	1996
Janv	7	9	18
Févr	15	◇	◇
Mars	25	◇	◇

Info	1998	1997	1996
Janv	5	8	15
Févr	12	◇	◇
Mars	18	◇	◇

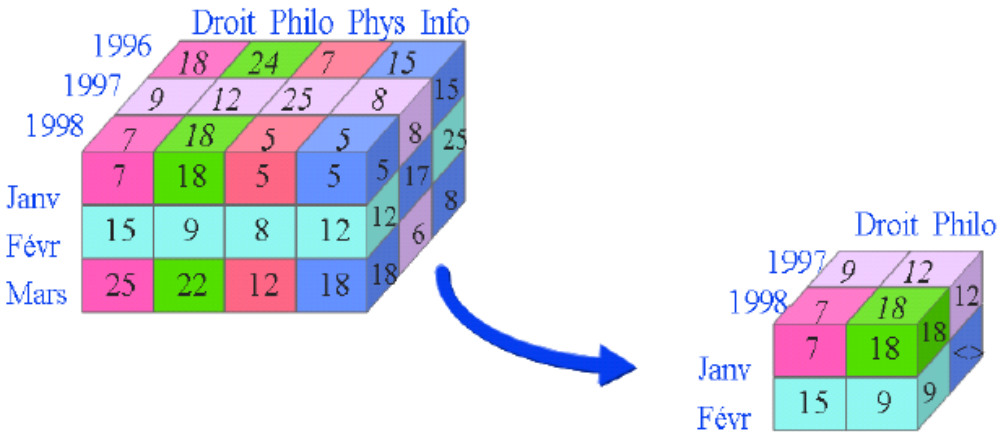
Phys	1998	1997	1996
Janv	5	25	7
Févr	8	◇	◇
Mars	12	◇	◇

Philo	1998	1997	1996
Janv	18	12	24
Févr	9	◇	◇
Mars	22	◇	◇

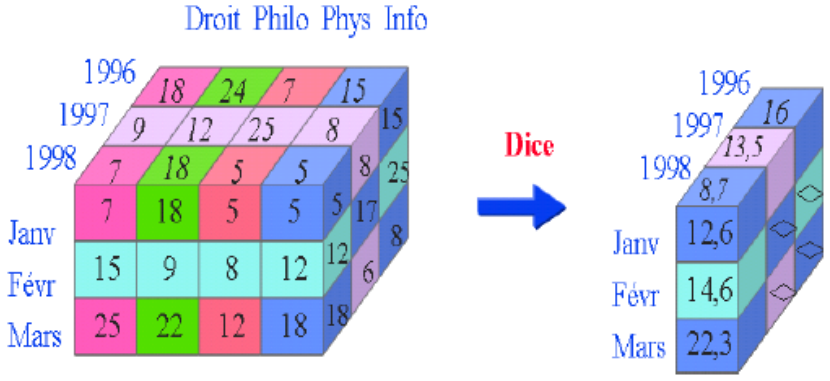
Entrepôt de données : Data Warehouse

Opération sur les OLAP : Opérations sur le contenu des cubes :

- Slice (Restriction)



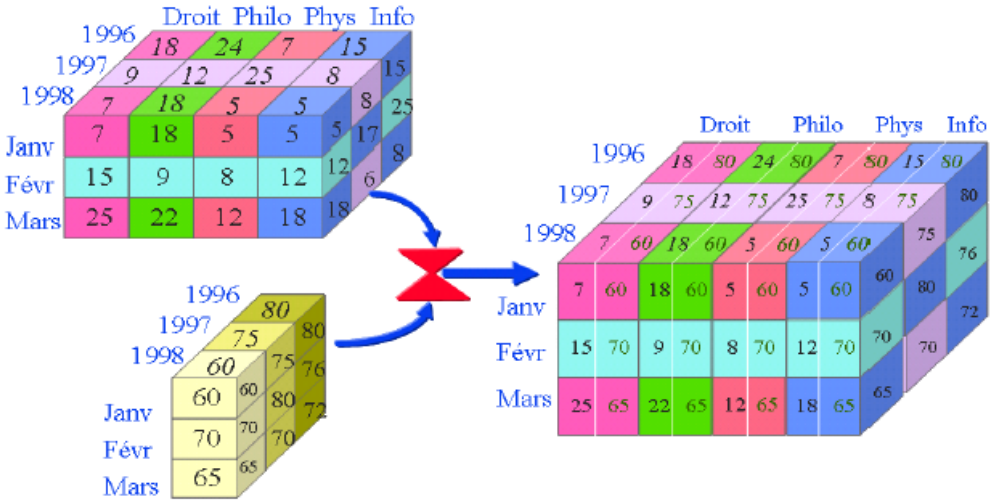
- Dice (Projection)



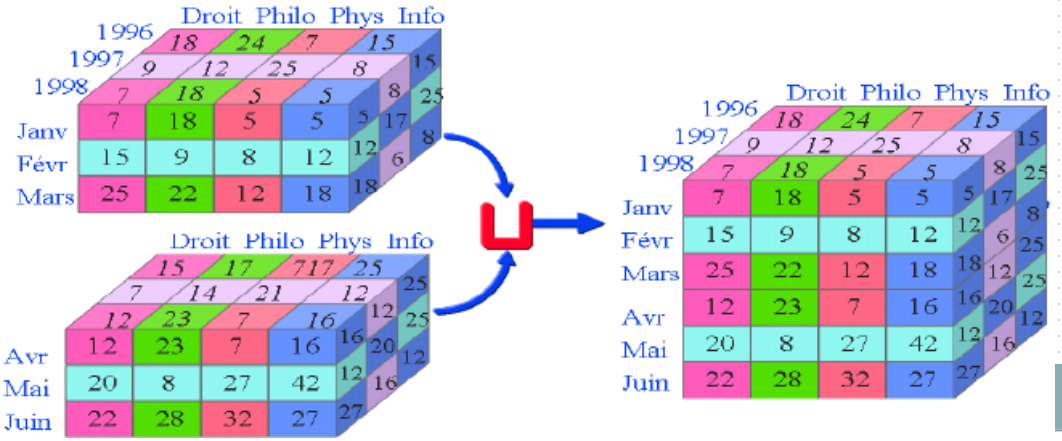
Entrepôt de données : Data Warehouse

Opération sur les OLAP : Opérations entre les cubes :

- Jointure



- Union



Entrepôt de données : Data Warehouse

Outils OLAP :

- BusinessObjects, BusinessObjects : https://www.businessobjects.com/
- SAS: https://www.sas.com/en_us/solutions/business-intelligence.html
- HarrySoftware , HarryPilot, HarryCube: https://www.decideo.fr/Business-Intelligence_r7.html
- Outil Tableau : https://www.tableau.com/
- Birt : https://www.eclipse.org/birt/









Entrepôt de données : Data Warehouse



- Les enjeux de l'approche entrepôt de données :

Les bénéfices peuvent être très différents suivant les entreprises et les contextes.

Avantages :

En séparant les systèmes opérationnels des systèmes décisionnels, les entrepôts de données offrent aux entreprises plusieurs avantages:

- Consolidation de données disparates et dispersées.
- Amélioration des flux de données en permettant une homogénéité des informations pour l'ensemble des utilisateurs.
- Assurer des gains de productivité par une meilleure connaissance du fonctionnement interne et des coûts de l'entreprise.
- Plus grande autonomie des utilisateurs.

Entrepôt de données : Data Warehouse

- ## Les enjeux de l'approche entrepôt de données :

Les bénéfices peuvent être très différents suivant les entreprises et les contextes.

Principaux facteurs de risque :

Les facteurs de risques sont multiples et l'entreprise doit impérativement les intégrer dans son diagnostic initial:

- L'approche entrepôt de données engage l'entreprise dans un véritable saut technologique qui devra être abordé par un réel changement culturel.
- Il existe un risque au niveau de la non utilisation ou de la mauvaise utilisation. D'où la nécessité de mise en place d'une politique de communication et de formation de l'ensemble des acteurs (informaticiens, opérationnels et décideurs).
- Le risque de sécurité des informations est également à prendre en compte en raison de la diffusion élargie de données. L'entreprise devra mettre en place de nouvelles procédures permettant la sécurité du système d'information.
- Risques liés à l'actualisation du système : les applications décisionnelles évoluent en permanence et .l' entreprise doit être capable d'anticiper et d'actualiser son système d'information.

Exemple d'un DW dans le domaine de télécoms

- **Sujets :**
  - Suivi du marché: lignes installées/ désinstallées, services et options choisis, répartition géographique, répartition entre public et différents secteurs d'organisations
  - Comportement de la clientèle
  - Comportement du réseau
- **Historique**
  - 5 ans pour le suivi du marché
  - 1 an pour le comportement de la clientèle
  - 1 mois pour le comportement du réseau
- **Sources**
  - Fichiers clients élaborés par les agences
  - Fichiers de facturation
- **Requêtes (Besoins)**
  - **Comportement clientèle**
  - **Comportement réseau**
  - **Nombre moyen d'heures par client, par mois et par région**
  - **Durée moyenne d'une communication urbaine par ville**
  - **Durée moyenne d'une communication internationale**

Exploitation des données



Une fois les données stockées, nettoyées, consolidées et accessibles, elles sont utilisables. Selon les besoins, différents types d'outils d'extraction et d'exploitation seront envisagés.

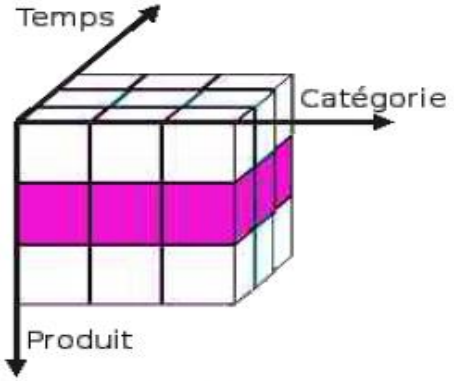
Analyse multidimensionnelle :

- L'**analyse multidimensionnelle** consiste à modéliser des données selon plusieurs axes. L'exemple le plus classique : le calcul du chiffre d'affaires par catégorie de client sur une gamme de produit donnée combine trois axes (le chiffre réalisé, la catégorie de clients et la ligne de produits). De nombreux autres axes supplémentaires peuvent être définis : zone géographique ou équipe commerciale en charge des opérations par exemple. Le cube "OLAP" (pour *Online analytical processing*) désigne la technologie analytique qui s'applique à ce modèle de représentation.

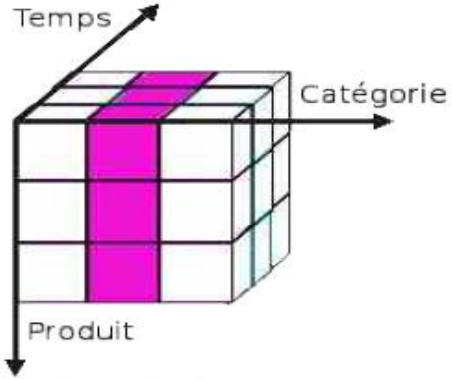
- Les structures multidimensionnelles **OLAP** (On Line Analytical Processing) permettent d'analyser des indicateurs (ventes, chiffre d'affaires, transactions…) et de les explorer suivants plusieurs dimensions (temps, produit, Catégorie…). Les choix de l'architecture OLAP vont influer sur toutes les composantes du système décisionnel : performance, volumétrie, temps de requête.

Exploitation des données

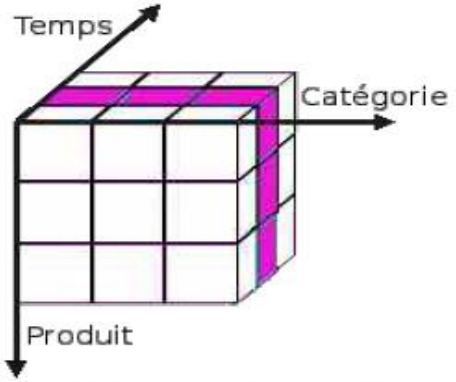
- **Analyse multidimensionnelle :**



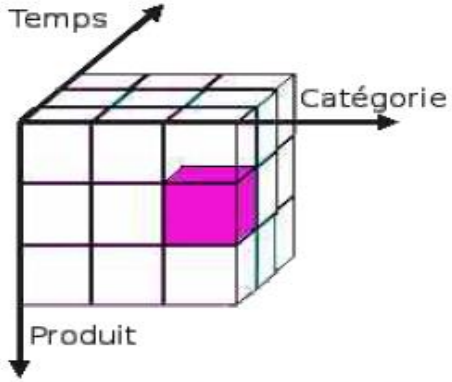
Evolution du chiffre d'affaire réalisé pour un produit par catégorie de client



Evolution du chiffre d'affaire réalisé pour une catégorie de client



Répartition du chiffre d'affaire par produit et par catégorie de client sur une période



Chiffre d'affaire pour un produit avec une catégorie de client à une période donnée.

Exploitation des données



Différents modes de stockage OLAP

- **MOLAP** (Multidimentional OLAP), est une solution de stockage qui garantit les temps de réponses, mais se traduit par des temps d'alimentation et de stockage plus importants.

- **ROLAP** (Relational OLAP) stocke les données dans une base de données relationnelle, mais détériore les temps de réponse, puisque les calculs sont effectués en dynamique lors de l'analyse. Le stockage est optimisé et laisse une plus grande liberté de requête.

- Les plates-formes décisionnelles évoluées permettent aujourd'hui une solution de continuité entre ces choix, en prévoyant notamment un choix hybride (**HOLAP**) où seule une partie des données sont pré calculées et stockées.

Exploitation des données



Recherches corrélatives : datamining, forage de données

- « Le **data mining désigne** l'ensemble des algorithmes et des méthodes destinés à l'exploration et l'analyse de grandes bases de données informatiques en vue de détecter dans ces données, des règles, des associations, des tendances inconnues (non fixées a priori), des structures particulières restituant de façon concise l'essentiel de l'information utile pour l'aide à la décision » (Stéphane Tufféry : http://data.mining.free.fr)

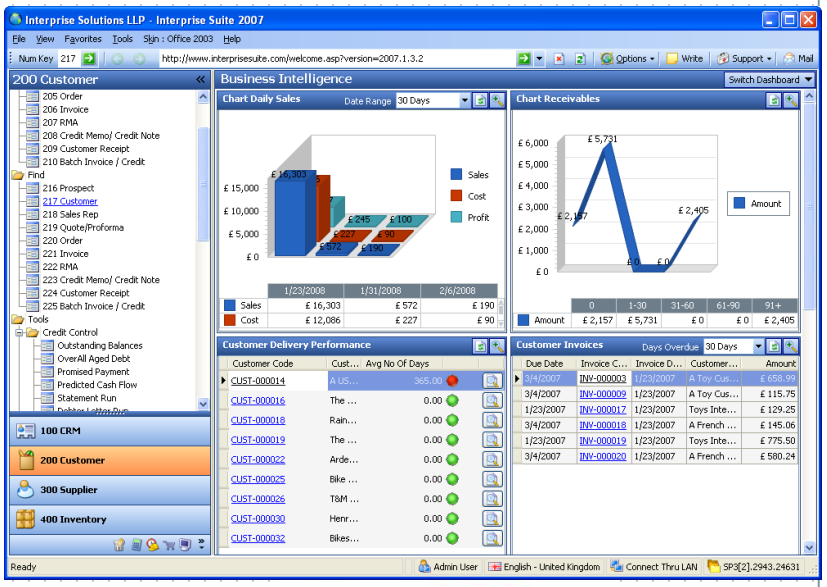
- En bout de course, les applications analytiques se chargent de recueillir les requêtes de l'utilisateur dans le langage de ce dernier puis de les communiquer à l'entrepôt, avant de produire les indicateurs de performance voulus. Au final, les résultats issus de ce traitement sont restitués et diffusés par le biais d'outils de *reporting*.

- **Recherches actuelles et futures : BigData**

Exploitation des données

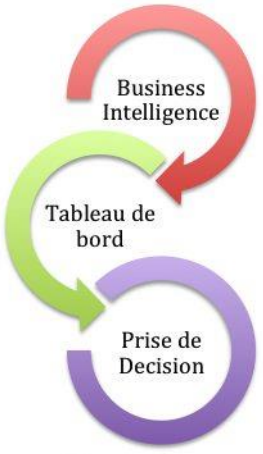
Tableaux de bord :

- « Un tableau de bord est un instrument de mesure de la performance facilitant le pilotage "pro-actif« d'une ou plusieurs activités dans le cadre d'une démarche de progrès. Le tableau de bord contribue à réduire l'incertitude et facilite la prise de risque inhérente à toutes décisions. C'est un instrument d'aide à la décision qui dynamise la réflexion et facilite la communication »



Reporting :

- Les outils de reporting proposent la réalisation de rapports selon un format prédéterminé. Les bases de données sont interrogées selon les requêtes SQL préparées lors de l'élaboration du modèle. Le rapport peut ensuite être diffusé sur l'Intranet, périodiquement en automatique ou ponctuellement à la demande.



OLTP et OLAP



- OLTP On Line Transaction Processus regroupe les concepts mis en place par un système destiné à l'automatisation d'un processus. On utilise pour cela une base de données transactionnelles, dont la mise à jour est faite en ligne.
- OLAP On Line Analysis Processus regroupe les concepts mis en place par un système d'analyse en ligne des données. On utilise pour cela une base de données décisionnelles, destinée à la prise de décision.
- Les deux systèmes diffèrent pour :
    - les utilisateurs ;
    - le contenu des données ;
    - la structure de la base de données ;
    - l'administration du système.

OLTP et OLAP

OLTP	OLAP
Utilisateurs	
Les utilisateurs sont les rouages de l'entreprise	Les utilisateurs observent les rouages de l'entreprise
Beaucoup d'utilisateurs concurrents	Peu d'utilisateurs (décideurs)
Une seule vision métier	Traite plusieurs visions métier
Exécutent un grand nombre de fois la même tâche	Lisent uniquement les données qui sont souvent récapitulées.
Lisent et modifient les données (système vivant)	Les demandes sont similaires mais différentes.
Exigent des performances (temps réel pour augmenter la productivité) ERP, GPAO, RH...	
Contenu des données	
Nécessaire au fonctionnement de l'entreprise	Utilisé pour analyser le fonctionnement de l'entreprise.
Normalisation en 3FN	Agrégée (dénormalisée)
Non historisé	Le temps est fondamental
Structures	

OLTP et OLAP

Structures	
OLTP	**OLAP**
Beaucoup de tables	Peu de tables mais de grande taille
Petites requêtes sur sur une seule table	Requêtes larges sur une grosse quantité de données
Temps de réponses instantanés (temps réel)	Temps de réponse de quelques secondes à plusieurs minutes.
Administration	
Forte disponibilité	Disponibilité faible
Sauvegardes fréquentes	Sauvegardes peu fréquentes, mais très volumineuses.
Beaucoup de petites transactions	En règle générale, une transaction par jour.
Peu de maintenance off-line	Beaucoup de maintenance off-line

Références et bibliographies

- Blondel François (2009), Bien gérer avec un ERP. Synergie entre supply chain, production, finance et RH, Dunod.
- Deixonne J.Luc (2006), Piloter un projet ERP. transformer et dynamiser l'entreprise par un système d'information intégré et orienté métier, Dunod, 2e éd.
- M.H. Delmond, Y. Petit, J.M. Gautier (2008), Management des systèmes d'information, Dunod, 2e éd.
- Larocca Danielle (2005), *SAP R/3*, Campus Press.
- K. Laudon, J. Laudon, E. Fimbel, S. Costa (2010), Management des systèmes d'information, Pearson, 10e éd.
- Lequeux J.Louis (2008), *Manager avec les ERP. Architecture orientée services*
- *(SOA)*, Eyrolles, 3e éd.
- Lumbroso Maurice (2007) Microsoft Navision. Développez pour l'ERP, ENI Editions.
- Tomas J.L. (2007), *ERP et PGI Sélection, méthodologie de déploiement et gestion du changement. Les clés du succès, les facteurs de risques,* Dunod, 5e éd.
- Tournant Laurence, Azan Wilfrid (2003) Réussir votre projet *ERP* , Afnor.
- Vogel Andreas, Kimbell Ian (2006) My *SAP ERP pour les nuls, First Interactive*.

Fin de la présentation

